Hướng dẫn cấu trúc dự án P1

Delta Lake vs Apache Iceberg vs Apache Hudi dưới workload cập nhật nhiều — Big Data Analytics and Management (TLU 2026)

Tác giả: Hà Văn Vinh, Đỗ Thị Lan · **Cập nhật:** 03/11/2026 · **Thư mục:** `C:\Users\Admin\lakehouse-p1` · **Repo:** https://github.com/vinhha195-oss/lakehouse-p1

Tài liệu giải thích từng thư mục và file trong dự án, quy trình đã thực hiện và các bước còn lại để hoàn thiện. Các mục được gom theo vai trò, không theo thứ tự chữ cái trong Windows Explorer.

1. Bức tranh tổng thể: dự án đi qua 5 bước

Bước	Việc làm	Nằm ở đâu
1. Dữ liệu	Tải TSM-Bench d1 (dữ liệu thủy văn, 4,8 GB), cắt 10 trạm × 20 cảm biến × 17 ngày	`_ext\`
2. Sinh workload	Bộ sinh sensor-LST tạo luồng thao tác: nạp, 40 batch có dữ liệu trễ, xóa trạm-ngày, kèm ground truth	`sensorlst\workload.py`
3. Chạy thí nghiệm	8 notebook Kaggle, 395 lần chạy (3 format × 2 chế độ × 4 mức u × 3 chu kỳ compaction, lặp 5 lần)	`notebooks\`, `sensorlst\`
4. Phân tích	Gộp kết quả, chuẩn hóa theo tốc độ VM, xuất bảng và biểu đồ	`sensorlst\analyze.py` → `results\report\`
5. Viết & trình bày	Bài báo 14 trang, slide 20 trang, demo localhost, repo GitHub	`report\`, `demo\`, GitHub

2. Từng mục và nhiệm vụ

A. Mã nguồn chính: sensorlst\

Đây là "trái tim" của dự án; các notebook Kaggle chạy chính những file này.

File	Nhiệm vụ
`config.py`	Khai báo phiên bản (Spark 3.5.3, Delta 3.2.1, Iceberg 1.6.1, Hudi 0.15.0), các quy mô (smoke, small, demo) và ma trận thí nghiệm 3 format × 2 chế độ × 4 mức u × 3 chu kỳ compaction
`workload.py`	Bộ sinh workload sensor-LST: đọc TSM-Bench d1, sinh trước toàn bộ luồng thao tác ra file Parquet và tính ground truth (số dòng, tổng s0) để kiểm tra
`formats.py`	Adapter cho 4 layout (Delta, Iceberg, Hudi, Parquet) với cùng các lệnh: tạo bảng, append, upsert, xóa, compaction, time travel, đếm file và metadata; chứa các bản sửa lỗi Hudi
`queries.py`	Năm truy vấn phân tích Q1–Q5
`run_one.py`	Chạy một cấu hình trong một JVM Spark mới: đo từng thao tác, đếm byte ghi, so với ground truth, ghi kết quả ra một file JSON
`matrix.py`	Chạy nhiều cấu hình (một shard): 3 vòng, xáo thứ tự ngẫu nhiên, giới hạn thời gian, chạy tiếp được khi bị ngắt
`analyze.py`	Gộp JSON, chuẩn hóa thời gian theo VM, xuất bảng CSV và biểu đồ fig_*.png

B. Chạy thí nghiệm

Mục	Nhiệm vụ

notebooks\sensorlst_u00/01/05/20.ipynb	4 notebook lần 1–3 trên Kaggle, mỗi notebook một mức u, và 4 notebook u00b/01b/05b/20b cho lần 4–5; code sensorlst được nhúng sẵn bên trong
scripts\make_notebooks.py	Sinh lại notebook từ code trong sensorlst\
HUONG_DAN_KAGGLE.md	Hướng dẫn từng bước chạy trên Kaggle
scripts\show_run.py	In tóm tắt nhanh một file kết quả JSON

C. Kết quả: results\

Mục	Nội dung
kaggle\	Dữ liệu gốc chính thức: 395 file JSON từ 8 file zip Kaggle
report\	Kết quả đã phân tích: summary.csv, bảng theo truy vấn, hệ số hiệu chuẩn VM, 8 biểu đồ dùng trong bài

D. Báo cáo

Mục	Nhiệm vụ
report\BaoCao_P1_Lakehouse.docx / .pdf	Bài báo để nộp, 14 trang, khổ A4, chữ 13 pt
report\Slides_P1_Lakehouse.pptx / .pdf	Slide trình bày, 20 trang; bản .pptx sửa được chữ, bảng và ghi chú
report\build_slides_pptx.py, build_slides_pdf.py	Xuất slide online sang PowerPoint và PDF
report\make_figures.py	Vẽ hình 1 (sơ đồ kiến trúc, nhãn tiếng Việt)
report\make_formulas.py	Tạo ảnh công thức dùng trên slide
report\make_guide.py	Tạo tài liệu hướng dẫn này
report\to_pdf.ps1	Gọi Microsoft Word để xuất .docx sang PDF
scripts\check_report.py	Kiểm tra bài: số trang, tham chiếu hình/bảng, trích dẫn, con số chính
paper\main.tex, paper_overleaf.zip	Bản bài báo IEEE tiếng Anh (LaTeX) để biên dịch trên Overleaf; không bắt buộc
scripts\check_paper.py	Kiểm tra bản LaTeX: trích dẫn, tham chiếu, file hình

E. Demo

Mục	Nhiệm vụ
run_demo.bat	Nhấp đúp để mở demo tại http://localhost:8501
report\KichBan_Demo.docx / .pdf	Kịch bản trình bày demo 5 phút, xử lý sự cố, câu hỏi có thể gặp
demo\app.py	Giao diện web Streamlit: ghi batch, xóa, compaction, time travel
demo\worker.py	Chạy một phiên Spark cho mỗi format, nhận lệnh từ giao diện
demo\test_app.py, demo\test_worker.py	Test tự động cho demo
scripts\demo_time_travel.py	Demo time travel bản dòng lệnh (bản đơn giản)

F. Kiểm thử, môi trường và tài liệu

Mục	Nhiệm vụ
`tests\test_workload.py`	7 unit test cho bộ sinh workload
`README.md`	Mô tả dự án bằng tiếng Anh, hiển thị trên GitHub
`requirements.txt`	Danh sách thư viện Python cần cài
`.gitignore`	Những thư mục không đưa lên GitHub
`scripts\local_env.sh`	Thiết lập Java và Hadoop để chạy Spark trên Windows
`.venv\` (≈ 1 GB)	Môi trường Python riêng của dự án (PySpark, Streamlit…)
`_ext\` (≈ 1,8 GB)	Công cụ tải về: Java portable, winutils, gói Delta/Iceberg/Hudi, dữ liệu đã cắt d1_small.parquet

G. Thư mục tạm của demo (không nộp, không có trên GitHub)

Mục	Ghi chú
`staging\demo_u20\`	Luồng thao tác của demo; demo tự tạo lại nếu thiếu
`work\`	Thư mục làm việc của Spark khi chạy demo, đang trống

3. Quy trình đã thực hiện

1. **Xây dựng (30/10):** viết sensorlst\, sửa các lỗi Hudi, chạy thử 26 cấu hình nhỏ trên máy và 3 cấu hình quy mô thật; tất cả đều đúng.
2. **Chạy thí nghiệm (31/10):** lần 1–3 trên 4 notebook Kaggle; lần 4–5 chạy thêm ngày 6/11 trên 4 notebook khác, tổng 395 lần chạy, tải 8 file zip về results\kaggle\.
3. **Phân tích (31/10):** analyze.py tạo results\report\; phát hiện các VM chênh tốc độ tới 1,58 lần nên bổ sung bước chuẩn hóa.
4. **Viết (01/11):** bài báo Word 14 trang theo mẫu, 20 slide, demo localhost, cập nhật proposal.
5. **Hoàn thiện (03/11):** điền tên tác giả, đẩy repo lên GitHub, thêm link vào bài và slide, rà soát báo cáo (tham chiếu hình/bảng, trích dẫn, con số).

4. Trạng thái và việc còn lại

Hạng mục	Trạng thái
Proposal (Mốc 1)	Xong
Code + thí nghiệm (Mốc 2)	Xong — 395/395 lần chạy khớp ground truth
Bài báo 12–14 trang	Xong — 14 trang, đã rà soát
Tên tác giả, link GitHub	Xong
Repo GitHub	Xong — github.com/vinhha195-oss/lakehouse-p1
Slide	Xong — cần tự rà một lượt và xuất PDF
Demo	Xong — cần tập trình diễn

Các bước còn lại:

- **Bước 1 – Xuất slide ra PDF:** mở link slide trên claude.ai → Share → Export → PDF (hoặc .pptx).
- **Bước 2 – Rà slide** một lượt; slide nào chữ tràn hoặc lệch thì sửa trực tiếp trên web.

- **Bước 3 – Tập demo khoảng 5 phút:** nhấp đúp run_demo.bat → khởi động chế độ MoR → ghi 4 batch → xóa trạm st0 → time travel xem lại st0 → compaction.
- **Bước 4 – Nộp:** PDF bài báo, slide (PDF/.pptx), link GitHub; trình diễn demo khi thuyết trình.

Lưu ý khi sửa bài: file mẫu dùng để dựng bài ban đầu đã bị xóa, nên mọi chỉnh sửa làm trực tiếp trong Word rồi xuất lại PDF (File → Save As → PDF, hoặc powershell report\to_pdf.ps1). Thân bài đang dùng Times New Roman, tiêu đề mục dùng Segoe UI; nếu cần thống nhất một phông, đổi trong Word trước khi xuất PDF.